

Méthodes expérimentales et analyse de données

Ing-1100

Intro : principes de base

Séance 1

Guilherme D. Garcia | fr.gdgarcia.ca/Ing1100



Mesures d'accommodement

Important :

Les étudiants qui ont droit à des mesures d'accommodement en cours de session doivent procéder à leur activation immédiatement dans monportail.ulaval.ca/accommodement afin que celles-ci puissent être mises en place.


Objectifs

- **Formuler et tester** des hypothèses de recherche [en linguistique]
- **Se familiariser** avec les éléments de base de l'analyse de données quantitatives
- **Interpréter et synthétiser** des résultats statistiques dans un rapport scientifique

Nos analyses

- Notre cours examine les données de façon **quantitative**
- Une analyse **qualitative** est également possible, bien qu'elle ne fasse pas partie de nos objectifs

Familiarisez-vous avec la structure du cours



Nos matériels

👉 Livre du cours : fr.gdgarcia.ca/lng1100

Garcia (2024)

Livres additionnels qui seront utilisés :

Français	Barnier (2024)
	Larmarange (2023)
Anglais	Wickham et al. (2023)
	Garcia (2021)

introduction à R
R + statistique
R (très détaillé)
R + statistique

Évaluation et IA

- Vous êtes encouragés à utiliser l'IA pendant le cours si vous voulez, spécialement pour réviser vos réponses et vos codes

☞ **Toutefois**, gardez deux choses à l'esprit :

1. vos examens (50 %) ne sont **pas** à livre ouvert, et vous n'aurez pas d'ordinateur pour vous aider. Donc, si vous dépendez de l'IA pour vos analyses, vous aurez des problèmes
2. l'IA combine souvent des fonctions provenant de multiples extensions R, alors que dans ce cours nous utiliserons uniquement **une** famille d'extensions (plus unifié). Limiter et harmoniser votre répertoire de fonctions rendra votre apprentissage plus clair, plus cohérent et plus facile à consolider

☞ Dans le cours, il faut pratiquer le codage **fréquemment**. C'est la façon la plus facile de réussir

Un petit sondage

forms.office.com/r/G700T82tNs



Plan de la séance

1. Les données peuvent être trompeuses
2. Nos outils : **R + RStudio**
3. La structure du cours; principes généraux de la recherche (linguistique); hypothèse, expérimentation; comité d'éthique; design expérimental : sondage, ABX/AXB, tâche de jugement à choix forcé, etc.

1 Les données peuvent être trompeuses

Exemple 1

Quel est le problème ici?

Le chômage a baissé de 50 % le mois dernier

Solution :

☞ Si le taux de chômage est passé de 2 % à 1 %, c'est effectivement une baisse de 50 %, mais cela peut induire les gens en erreur en leur faisant penser qu'il y a eu une amélioration massive de l'emploi

Exemple 2

Quel est le problème ici?

Le revenu moyen dans la ville A est de 100 000 \$

Solution :

☞ Si un petit nombre de personnes très riches vivent dans la ville, la moyenne peut être fortement biaisée. La médiane ou le mode pourraient fournir une image plus précise du revenu typique

Exemple 3

Quel est le problème ici?

Le taux d'intérêt a augmenté de 2 % l'année dernière

Solution :

☞ Si le taux est passé de 5 % à 7 %, c'est une augmentation de 2 points de pourcentage, mais une augmentation de 40 % du taux d'intérêt lui-même

Exemple 4

Quel est le problème ici?

Un test médical avec une précision de 95 % a donné un résultat positif. Par conséquent, le patient a 95 % de chances d'avoir la maladie

Solution :



☞ Sans tenir compte de la prévalence de la maladie dans la population, cette affirmation peut être trompeuse. Si la maladie est rare, un résultat positif peut toujours être un faux positif

Pour bien comprendre le problème, on utilise [le théorème de Bayes](#)↓

Exemple 5

Quel est le problème ici?

- Une figure peut-elle influencer vos conclusions?



Vos connaissances de base

forms.office.com/r/qqd8t6Tv1G




2 Nos outils : R + RStudio

RStudio

- On commence à travailler avec RStudio à partir de **la semaine prochaine**

👉 Lisez le chapitre 1 de notre livre **avant** notre séance




- Tous ces outils sont disponibles dans la version en ligne posit.cloud¹

¹EDI = environnement de développement intégré. Normalement, on choisit un EDI ou un éditeur de texte pour travailler avec le codage.

R

Langage + EDI simple



```
R version 4.3.1 (2023-06-16) -- "Beagle Scouts"
Copyright (C) 2023 The R Foundation for Statistical Computing
Platform: aarch64-apple-darwin20 (64-bit)

R is free software and comes with ABSOLUTELY NO WARRANTY.
You are welcome to redistribute it under certain conditions.
Type 'license()' or 'licence()' for distribution details.

Natural language support but running in an English locale

R is a collaborative project with many contributors.
Type 'contributors()' for more information and
'citation()' on how to cite R or R packages in publications.

Type 'demo()' for some demos, 'help()' for on-line help, or
'help.start()' for an HTML browser interface to help.
Type 'q()' to quit R.


[R.app GUI 1.79 (8238) aarch64-apple-darwin20]
>
```



- R inclut son propre EDI
- Mais il est trop simple

RStudio

EDI très puissant et intuitif



1. Notre analyse
2. Notre résultat
3. Nos variables
4. Fichiers locaux, figures

Tidyverse

Les extensions (bibliothèques)

- Extension (bibliothèque; *package*) : collection de fonctions, de données et de documentation regroupées ensemble
- R contient plus de **17 000** extensions

☞ Dans notre cours, on utilisera principalement l'extension `tidyverse`



- On va explorer en détail [cette famille d'extensions](#) dans deux semaines

3 Principes généraux de la recherche (linguistique)

Le processus typique

1. Trouver un sujet/problème approprié
2. Poser une question² (et une hypothèse?)
3. Développer une expérience et/ou **collecter et examiner des données**
4. **Évaluer les résultats par rapport à l'hypothèse**
5. **Communiquer** et publier les résultats

👉 Dans notre cours, on met l'accent sur les éléments **mis en évidence**

²L'une des étapes les plus difficiles.

Exemple

Un sujet et une question de recherche

1. **Sujet** : la production et la perception des voyelles /y/, /ø/, /œ/³ en français
 - lunette — neutre — jeune ← très difficile pour des apprenants
2. Les apprenants qui prononcent mal ces voyelles sont-ils capables de les distinguer?
 - Si oui, il s'agit d'un problème de **production**
 - Si non, il s'agit d'un problème de **perception** aussi
3. On peut créer une expérience pour examiner le comportement des apprenants
 - Par conséquent, il faut consulter le site du **CÉRUL** (Comités d'éthique)
 - Parfois, le projet sera exempté (c'est rare...)
 - **Alternative** : utiliser des données déjà disponibles (p. ex., en ligne)

³Alphabet phonétique international.

Exemple

Design expérimental

- Quel type de collecte de données...?
 - Sondage (MS Forms et Google Forms : gratuits et faciles) ← Notre point de départ cette session
 - ABX/AXB (PsychoPy, Gorilla, Praat, etc.)
 - Jugement à choix forcé (idem)
 - ...

Exemple

Design expérimental : sondage

- Le sondage est probablement le type de collecte de données le plus simple

☞ Quel type de question pourrait-on poser dans un sondage sur les voyelles françaises?

« Écoutez le mot suivant et tapez ce que vous entendez dans la case ci-dessous »

- On utilise plusieurs mots du français : ceux qui contiennent les voyelles ciblées et ceux qui contiennent d'autres voyelles (les **éléments distracteurs**)

☞ Enfin, on a de nombreuses réponses qui peuvent être analysées

Exemple

Design expérimental : ABX/AXB

- Méthode de comparaison entre deux stimulus
- Imaginons un mot non réel : « zule » /zyl/
- Le participant écoute la séquence /zø1/ — /zyl/ — /zyl/

☞ On pose la question :

- Le **troisième** mot est-il identique au premier ou au deuxième mot?

1	2
---	---

 AB**X**
- Le **deuxième** mot est-il identique au premier ou au troisième mot?

1	3
---	---

 A**X**B
- Les réponses nous permettent d'évaluer la précision perceptuelle des participants

Exemple

Design expérimental : choix forcé

- On **force** le participant à choisir une option (entre deux/trois/etc.)
- Imaginons une paire minimale comme « peu » /pø/ et « pu » /py/
- Le participant écoute /pø/

☞ On pose la question :

- Quel mot venez-vous d'écouter? peu pu
- Les réponses nous permettent d'évaluer la précision perceptuelle des participants

Design expérimental

- Supposons l'exemple ABX. On peut examiner plusieurs **variables** d'intérêt :
 - La voyelle (3 voyelles ciblées) et la précision de la réponse (0 ou 1)
 - Le temps de réaction pour chaque séquence
 - Le niveau de compétence linguistique du participant
 - L'âge du participant
 - ...
- Finalement, on collecte aussi des données des locuteurs natifs (**groupe de contrôle**) pour s'assurer que l'expérience fonctionne

Question

👉 Quel serait le problème si l'on ne collectait pas de données du groupe de contrôle?

Question • correction

- ☞ Sans groupe de contrôle, un résultat faible est **ambigu** : vient-il des apprenants ou de l'expérience elle-même?
- Si les locuteurs natifs réussissent la tâche, on peut attribuer la difficulté aux **apprenants** : c'est le résultat qui nous intéresse
- S'ils échouent aussi, c'est la **tâche** qui pose problème (stimuli trop courts, enregistrements de mauvaise qualité, consignes ambiguës...) et les données des apprenants ne veulent rien dire
- ☞ Le groupe de contrôle fournit donc un **point de référence** : il permet d'interpréter la *taille* de l'effet, et pas seulement son existence

Exemples additionnels

ABX/AXB

« Écoutez les trois sons suivants : A, X, B. Le son X est-il plus semblable à A ou à B? »

Exemple



Exemples additionnels

choix forcé

« Lequel de ces deux mots sonne plus naturel (en anglais)? »

[¹kl.mɛ.sər]

[kl.¹mɛ.sər]

Pratique

Question de recherche : l'accent régional d'un locuteur influence-t-il la perception de son intelligence dans un contexte professionnel?

Méthode : une enquête où les participants écouteront des enregistrements de différents locuteurs avec différents accents régionaux présentant les mêmes informations professionnelles. Les participants devront ensuite évaluer l'intelligence perçue des locuteurs sur une échelle de 1 à 10.

1. Quelles variables sont pertinentes dans l'étude en question?
2. Quels sont les problèmes potentiels?

Pratique • correction

1. Les variables

- **Variable dépendante** : l'intelligence perçue, sur une échelle de 1 à 10 → données **scalaires** (ordinales), et non continues
- **Variable indépendante** : l'accent régional du locuteur → variable **catégorique**
- **Variables à contrôler** :
 - le contenu du message : identique pour tous les locuteurs
 - la voix du locuteur (sexe, âge, débit) et la qualité de l'enregistrement
 - l'origine régionale du participant : évalue-t-il son propre accent plus favorablement?
 - la familiarité du participant avec chacun des accents

2. Les problèmes potentiels


- ☞ **Un seul locuteur par accent** : on ne peut plus distinguer l'effet de l'*accent* de celui de la *voix*. Il faut plusieurs locuteurs pour chaque accent
- **Désirabilité sociale** : les participants devinent l'objectif et évitent de paraître préjugés → ajouter des éléments distracteurs
- **Effet d'ordre** : il faut randomiser ou contrebalancer l'ordre des enregistrements
- **Construction floue** : « l'intelligence perçue » n'est pas définie, et l'écart entre 1 et 2 n'est pas forcément celui entre 9 et 10
- **Éthique** : l'étude porte sur des préjugés linguistiques → consultez le [CÉRUL](#)

Méthodes → analyse

- Notre méthode de collecte de données détermine le type de données dans notre analyse :
 - Temps de réaction = données continues → p. ex., **régression linéaire**
 - Choix forcé = données catégoriques (binaires) → p. ex., **régression logistique**
 - Échelle de classification = données scalaires → p. ex., **régression ordinale**
 - ...
- Il y a toujours plusieurs méthodes appropriées d'analyse pour n'importe quel type de données

☞ Par contre, on trouve aussi plusieurs choix d'analyse qui sont **incorrects**

Synthèse



Semaine prochaine

👉 Lisez attentivement les chapitres 1 et 2 de notre livre numérique

- Lisez Barnier (2024, ch. 1–3; 5–7)

4 Annexe : le théorème de Bayes

Théorème de Bayes et tests médicaux

Si vous vous intéressez à la question

On ne va pas étudier ce théorème ce semestre. Mais si vous êtes curieux :

On considère un test avec une précision de 95 %, et une maladie rare ($\frac{1}{1000}$). Quelle est la probabilité d'avoir la maladie si le résultat du test est **positif**?

[Retourner↑](#)

Définition des probabilités

La probabilité d'avoir la maladie $P(M)$:

$$P(M) = \frac{1}{1000}$$

$$P(\neg M) = 1 - P(M) = \frac{999}{1000}$$

$$P(+ \mid M) = 0,95$$

$$P(+ \mid \neg M) = 0,05$$

Théorème de Bayes

Le théorème de Bayes :

$$P(M | +) = \frac{P(+ | M) \times P(M)}{P(+)}$$

$$P(+) = P(+ | M) \times P(M) + P(+ | \neg M) \times P(\neg M)$$

$$= 0,95 \times \frac{1}{1000} + 0,05 \times \frac{999}{1000}$$

$$= 0,0509$$

$$P(M | +) = \frac{0,95 \times \frac{1}{1000}}{0,0509}$$

$$\approx \boxed{1,87 \%}$$

[Retourner↑](#)

Théorème de Bayes

Le théorème de Bayes est formulé comme suit :

Probabilité a posteriori : $P(M \mid +)$

$$\begin{aligned} &= \frac{\text{Vraisemblance} \times \text{Probabilité a priori}}{\text{Vraisemblance marginale}} \\ &= \frac{P(+ \mid M) \times P(M)}{P(+)} \\ &= \frac{P(+ \mid M) \times P(M)}{P(+ \mid M) \times P(M) + P(+ \mid \neg M) \times P(\neg M)} \end{aligned}$$

Où $P(M)$ est la probabilité *a priori* de la maladie, $P(+ \mid M)$ est la vraisemblance du test positif sachant la maladie, et $P(+)$ est la vraisemblance marginale d'un test positif.

[Retourner[↑]](#)

Références

Barnier, J. (2024). *Introduction à R et au tidyverse*.

Garcia, G. D. (2021). *Data visualization and analysis in second language research*. Routledge.

Garcia, G. D. (2024,). *Méthodes expérimentales et analyse de données*.

Larmarange, J. (2023). *Introduction à l'analyse d'enquêtes avec R et RStudio*.

Wickham, H., Çetinkaya-Rundel, M., & Grolemund, G. (2023). *R for data science*. O'Reilly Media, Inc.