

Méthodes expérimentales et analyse de données

Ing-1100

Question de recherche, collecte de données, intro à R

Séance 2

Guilherme D. Garcia | fr.gdgarcia.ca/Ing1100



Plan de la séance

1. Question de recherche et collecte de données
2. Intro à R (Barnier, 2024, chapitres 1–3; 5–7)
3. Pratique

Question de recherche

☞ Vos questions déterminent vos méthodes (collecte + analyse)

1. Choisissez un sujet qui vous intéresse

2. Développez des questions de recherche

- **Examinez les études déjà publiées** (p. ex., vers la fin des articles)
- Discutez avec vos collègues et profs
- Explorez des données existantes et observez les patrons qui émergent

☞ Votre question ne doit être ni trop spécifique ni trop générale :



3. Considérez des résultats possibles et les étapes suivantes

Ordonnez les questions (spécifique → générale)

- A. Comment les locuteurs du français montréalais produisent-ils les voyelles nasales [ã] et [ẽ]¹ en langage familier?
- B. Quelle est la variation exacte de la fréquence fondamentale (Fo)² pour la voyelle [i] dans le mot « si » lorsqu'elle est prononcée par des locuteurs bilingues français-anglais montréalais?
- C. Qu'est-ce qui influence la langue?
- D. Quel est le rôle des processus phonologiques dans l'harmonie vocalique³ du finnois?
- E. Comment les facteurs sociaux affectent-ils le changement linguistique?

¹ Par exemple, « temps » et « pain ».

² La fréquence initiale d'un son brut généré dans les cordes vocales.

³ Le processus dans lequel une voyelle devient plus similaire à une autre voyelle : lotu → lutu.

Ordonnez les questions • correction

- B. Quelle est la variation de la fréquence fondamentale (F_0) pour la voyelle [i] dans le mot « si » lorsqu'elle est prononcée par des locuteurs bilingues français-anglais montréalais?
- A. Comment les locuteurs du français montréalais produisent-ils les voyelles nasales [ã] et [ẽ] en langage familier?
- D. Quel est le rôle des processus phonologiques dans l'harmonie vocalique du finnois?
- E. Comment les facteurs sociaux affectent-ils le changement linguistique?
- C. Qu'est-ce qui influence la langue?

Votre projet de recherche

- Un projet de recherche doit être **réaliste**, cela veut dire que :
 1. vous avez le **temps** pour suivre toutes les étapes nécessaires
 2. vous avez la **connaissance de base** exigée dans le projet
 3. vous connaissez les aspects **techniques** et **logistiques**⁴ impliqués
- ☞ Un projet prend du temps, même si les points 1–3 sont très clairs
- **Deux problèmes typiques :**
 - on sous-estime le temps et la difficulté des étapes nécessaires
 - on est trop général dans notre question ou dans notre sujet de recherche

⁴Approbation éthique, collecte de données, paiement des participants, accès aux équipements, etc.

Collecte de données

Logiciels

- Plusieurs méthodes d'éllicitation de données exigent des logiciels spécifiques
- Quelques options :
 - [PsychoPy](#), [OpenSesame](#), [Praat](#)
 - [Experiment Builder](#), [E-Prime](#), [MATLAB](#), [SuperLab](#)
- En plus, de **nombreuses** options pour des expériences en ligne

gratuits

\$\$\$

☞ Tout cela dépend de votre **question de recherche**

Bases de données


De quel type de données avez-vous besoin...?

- Écrites? Faciles à collecter, mais parfois difficiles à analyser
- Orales? Comment coder les données?
- Jugement?
- etc.

Bases de données

OSF

- Base de données générale (plusieurs domaines/sujets) : osf.io
- L'option la plus importante actuellement
- *Preprints* + matériels supplémentaires (y compris des données, des *scripts*, etc.)



Bases de données

IRIS

- Base de données des études sur une langue seconde : iris-database.org



Bases de données

CHILDES

Spécifique pour l'acquisition du langage⁵ : childes.talkbank.org


CHILDES		Child Language Data Exchange System
CHILDES is the child language component of the <i>TalkBank</i> system. TalkBank is a system for sharing and studying conversational interactions.		
System	Database	Manuals
Ground Rules Contributing New Data IRB Principles Overviews and Introductions	**Index to Corpora** Browseable Database LuCID Toolkit childes-db Hints on Downloading	CHAT - CLAN - MOR Tutorial Screencasts SLP's Guide to CLAN and 中文
Links	Programs	Contact
TalkBank Other Child Language sites Research based on CHILDES Child Language Diaries	CLAN - Example Files XML creator and XML Schema Related Software	Brian MacWhinney : homepage How to subscribe to Mailing Lists
Phonology and Fonts	Ideas	Morphology and Lexicon
Phon and PhonBank Unicode and IPA for Mac Unicode and IPA for Windows	Topics in language acquisition Teaching Resources Bibliographies Building a New Corpus	Part of Speech Analysis by MOR MRC lexical dictionary ChildFREQ Site and Paper

⁵ Une partie du projet [TalkBank](http://TalkBank.org).

Bases de données

WALS


Excellente base de données sur des traits linguistiques : wals.info



Bases de données

Speech Accent Archive

Les accents natifs ou non natifs de l'anglais : accent.gmu.edu



Bases de données

CMU Pronouncing Dictionary

- speech.cs.cmu.edu/cgi-bin/cmudict



The CMU Pronouncing Dictionary

[query](#) | [phonemes](#) | [about](#)

- Look up the pronunciation for a word or phrase in CMUdict (version 0.7b)

☐ Show Lexical Stress

- Download the current CMU dictionary from SourceForge


<http://svn.code.sf.net/p/cmuspinx/code/trunk/cmudict>
Find an error? Please contact the maintainers! We will check it out. (See at bottom for contact information.)

Note: If you are looking for a dictionary for use with a speech recognizer, this dictionary is not the one that you are For that purpose, see <http://svn.code.sf.net/p/cmuspinx/code/trunk/cmudict/sphinxdict> or use [this tool](#).

Bases de données

Buckeye corpus


Parole naturelle (avec transcription) du centre-ouest américain : buckeyecorpus.osu.edu



Bases de données

Atlas sonore

- atlas.limsi.fr



Bases de données

Corpus de français parlé au Québec

- applis.flsh.usherbrooke.ca/cfpq/



The screenshot shows the homepage of the CFPQ (Corpus de français parlé au Québec) website. The header includes the University of Sherbrooke logo, the center's name, and the corpus title. A navigation bar lists menu items like Accueil, Présentation, Conventions, etc. The main content area features a large title 'Perdre ... ? Ou ne pas perdre ce qu'on dit ?' and a description of the corpus as a multimodal interaction corpus. A sidebar on the left lists the team members and statistics (712,300 words, 28,638 different words). The footer contains logos for the University of Quebec, the Canadian government, and the Social Sciences and Humanities Research Council of Canada, along with copyright information and a date of update.

UNIVERSITÉ DE SHERBROOKE Centre d'analyse et de traitement informatique du français québécois *Corpus de français parlé au Québec*

Faculté des lettres et sciences humaines CFPQ

Accueil Présentation Conventions Vue d'ensemble Renseignements Recherche mercredi 13 septembre 2023

ÉQUIPE

- Responsable
- ASSISTANTS
- Support technique
- Enregistrement
- Transcription et révision

STATISTIQUES

- 712,300 mots
- 28,638 mots différents

CONVENTIONS

Perdre ... ?
Ou ne pas perdre ce qu'on dit ?

Corpus de français parlé au Québec CFPQ

Corpus multimodal
Corpus qui intègre les trois dimensions caractéristiques
d'une interaction verbale en face-à-face,
à savoir ses dimensions verbale, paraverbale et gestuelle

Points de recherche
sur le site
et la version

Québec

Canada

Tous droits réservés © Université de Sherbrooke 2500, boul. de l'Université, Sherbrooke (Québec) CANADA J1K 2R1
Mise à jour le 23 janvier 2019 - Application développée avec cadriciel YII(version 1.1.22)

1 Intro à R

Questionnaire

forms.office.com/r/XgXnS2Y8wD




Projet R pour LNG-1100

Pourquoi un projet...?

- On concentre tous les fichiers du cours dans un seul dossier (dépôt Git)
- RStudio connaîtra déjà la localisation des fichiers à partir du fichier `project.Rproj`
- Maintenant, on continue sur RStudio en ligne

👉 Voici la structure de notre dépôt  [Git](#) :



2 RStudio

Références

Barnier, J. (2024). *Introduction à R et au tidyverse*.