

Méthodes expérimentales et analyse de données

Ing-1100

Analyse de données : concepts basiques

Séance 4

Guilherme D. Garcia | fr.gdgarcia.ca/Ing1100



Plan de la séance

Dans RStudio aujourd'hui

1. Visualisation de données avec l'extension `ggplot2`
2. Intro à l'analyse de données
 - échantillonnage et population
 - simulation des données
 - valeur p
 - test t (exemple)
3. Pratique

Visualisation de données

```
# Tableau sampleData.csv (format long) :  
participant  group  test  note  
<chr>       <chr>  <chr> <dbl>  
1 subject_1  control testA  4.4  
2 subject_1  control testB  6.9  
3 subject_1  control testC  6.3  
4 subject_2  control testA  6.5  
...
```

Pratique

1. Comment créer un graphique de boîtes à moustaches à partir du tableau ci-dessus?
2. Comment créer un graphique de moyennes + barres d'erreur?

Pratique • correction

Quand la variable x est catégorique (discrète), ce sont les deux figures les plus communes :

```
# 1. Boîtes à moustaches (box plots)
ggplot(data = d, aes(x = group, y = note)) +
  geom_boxplot()

# 2. Moyennes + barres d'erreur (stat_summary)
ggplot(data = d, aes(x = group, y = note)) +
  stat_summary()
```

1 L'analyse de données

Échantillon vs population

« Analysez les notes des apprenants de français à Québec »


- Supposez qu'il y en a 20 000 (la **population** complète)
- Chaque apprenant a complété un test de français (0-100)

☞ C'est **trop**! Donc, on en prélève un petit **échantillon**

On déduit la population à partir de l'échantillon

Cette technique est-elle précise...?

Population ($N = 20\,000$)



échantillonnage



inférence



Échantillon ($n = 50$)

Simulation de données

```
# Simuler 20 000 notes : la population
set.seed(1)
population = rnorm(n = 20000, mean = 74, sd = 5)

# Vérifier la moyenne des données simulées :
mean(population) # 73.97318 (suffisamment proche!)



# Prélever un échantillon de 50 participants de la population :
set.seed(2)
echant = sample(x = population,
                size = 50,
                replace = FALSE) # On ne répète pas les participants

mean(echant) # 74.17266 : très précis!

# set.seed(...) permet de reproduire les résultats
```

Simulation de données

- Voici la distribution des notes : la population présente une distribution normale¹



¹Ou une distribution [gaussienne](#).

Simulation de données

Important!

- On n'a **jamais** accès direct à la population² : on n'examine qu'un **échantillon**
- C'est une des raisons pour lesquelles on utilise la statistique inférentielle :
 - on « estime le tout à partir de la partie »

²Sauf si on parle d'une population minuscule!

Un autre groupe d'apprenants


- Maintenant, on veut examiner les apprenants de français à Montréal
 - Cette fois-là, on a simplement un échantillon de 50 participants
- ☞ Donc, on va comparer 50 participants de Québec et 50 participants de Montréal

Pratique en groupes (10 min)

1. Importez le fichier `villes.csv`
2. Calculez la note moyenne pour chaque groupe de participants
3. Ordonnez les notes en ordre décroissant
4. Exportez le tableau en tant que `villesOrdonnees.csv`
5. Créez un graphique pour comparer les deux groupes

Comparaison


- Moyennes ($\bar{x}$) des apprenants : Québec $\bar{x} = 74,2$ Montréal $\bar{x} = 69,6$
 - La question est si on peut conclure que les deux groupes sont **réellement différents**
- ☞ **Autrement dit** : les deux échantillons viennent-ils de deux populations **différentes**?



Comparaison

Hypothèse nulle (H_0) : il n'y a aucune différence réelle entre les groupes

☞ Autrement dit, il s'agit de la même population sous-jacente



La façon la plus simple d'analyser nos données : **test t** , un test **paramétrique**³

³Pour les données qui suivent la **loi normale** : voici un [short](#) et une [vidéo](#).


Test t • l'intuition

Un écart de 4,6 points, est-ce beaucoup?

- Ça dépend de la **variation** dans les données

Le même écart de 4,6 points dans les deux cas

Ville : ■ Montréal ■ Québec



$$t = \frac{\text{écart entre les moyennes}}{\text{variation attendue par hasard}}$$

 t exprime l'écart en **unités de bruit** :


$t = 4 \rightarrow$ l'écart est quatre fois plus grand que ce que le hasard produit d'habitude

La distribution t

Et si les deux villes formaient une seule population?

- On remélange les 100 notes, on refait deux groupes de 50, on recalcule t ... 10 000 fois

10 000 simulations sous H_0 – 3 d'entre elles atteignent $|t| \geq 4,10$



Voilà la **distribution t** : tout ce que le hasard produit quand il n'y a aucune différence. Centrée sur 0, elle ressemble à la normale, mais avec des queues plus épaisses

- Notre t tombe tout au bout de la courbe : cette **rareté**, c'est la valeur p

Test t

```
> t.test(note ~ ville, data = villes)
```

Welch Two Sample t-test

data: note by ville

t = -4.1049, df = 97.919, p-value = 8.385e-05

alternative hypothesis: true difference in means between group
Montréal and group Québec is not equal to 0

95 percent confidence interval:

-6.807543 -2.370457

sample estimates:

mean in group Montréal	mean in group Québec
69.5838	74.1728

Test t • interprétation

- `t.test(note ~ ville, ...)` — la syntaxe de la fonction, `note ~ ville`, c.-à-d. « l'analyse de la note **en fonction de** la ville »
- **Welch Two Sample t-test** — le type de test : *two sample* = bilatérale, c.-à-d. « l'un ou l'autre des échantillons pourrait avoir une moyenne plus élevée »
- `t = -4.1049 ... p-value` — notre statistique `t = -4,1` et notre valeur $p = 8,4 \times 10^{-5} = 0,000084$
- **95 percent confidence interval** — l'intervalle de confiance au niveau de 95 %
- **sample estimates** — les moyennes des deux échantillons

Test t • interprétation

Résumé :

- Notre test t indique que les deux groupes sont statistiquement différents ($p < 0,0001$)
- La probabilité d'observer la différence en question si l'hypothèse nulle est correcte est **minuscule** (notre seuil de décision est typiquement 5 %, soit 0,05)

☞ Donc, les apprenants de Québec ont la moyenne la plus élevée

Pratique


1. Dans le fichier `villes.csv`, sélectionnez les notes supérieures à 60
2. Créez un graphique de boîtes à moustaches
3. Exécutez un test t et interprétez les résultats
4. Lisez la documentation de la fonction `?t.test` et explorez l'argument `alternative`

Pratique

1. Importez `pisa_2025.RData` avec la fonction `load(" ... ")`, sélectionnez deux pays : Canada (CAN) et France (FRA)
2. Créez un graphique de boîtes à moustaches pour les résultats de sciences
3. Exécutez un test t et interprétez les résultats
4. Comment créer une figure où x = les trois tests et y = les scores moyens?


Résumé

☞ **Hypothèse nulle** : **a** et **b** ne sont pas différents
ils viennent de la **même population** ($p \geq 0,05$).
Autrement dit, $\mu_a = \mu_b$.



une seule distribution sous-jacente

☞ **Hypothèse alternative** : **a** et **b** sont différents
ils viennent de populations **différentes** ($p < 0,05$). Autrement dit, $\mu_a \neq \mu_b$.



deux distributions distinctes

Test $t \rightarrow$ ANOVA

- Il y a plusieurs limitations dans les tests t . Par exemple :
 - seulement deux groupes peuvent être comparés
 - seulement une variable peut être incluse dans l'analyse (ville ici)
 - ...

Semaine prochaine

- **ANOVA** : lisez attentivement [ch. 5 du livre du cours](#)
- Faites les exercices et consultez les solutions du chapitre avant la séance

(Garcia, 2024, ch. 5)

2 Annexe : les valeurs critiques

Le test t de Welch

Examinons l'équation du test t à nouveau ([chapitre 4](#) du livre du cours)


$$t = \frac{\bar{x}_1 - \bar{x}_2}{s \cdot \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \rightarrow \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

1. C'est le rapport **signal** ÷ **bruit** vu plus tôt, écrit en symboles : l'**écart des moyennes** divisé par le **bruit attendu** (variances et tailles d'échantillons combinées)
 2. Cela nous donnera une statistique t qui suppose des variances **inégales** entre les groupes
 3. Ensuite, avec les degrés de liberté des données, on consulte [un tableau](#) de valeurs critiques. Pour $\alpha = 0,05$ et une hypothèse **bilatérale**, cette valeur sera de $\approx |1,98|$. Donc, si notre valeur t est supérieure à cette valeur, on sera dans la **région critique**, ce qui nous permettra de rejeter l'hypothèse nulle
- 🔍 Examinez le tableau en question : quelle est la relation entre les degrés de liberté et les valeurs critiques de t ? Si notre hypothèse était **unilatérale**, quelles seraient les différences dans l'analyse?

La distribution t dans un test bilatéral

La région critique (rouge) = 5 % de la distribution

- C'est la même courbe qu'on a simulée plus tôt, vue autrement : au lieu de compter la **rareté** de notre t , on fixe une frontière à 5 % et on regarde de quel côté on tombe



👉 $|4,1|$ est **beaucoup** plus élevé que $|1,98|$ (ligne pointillée)

- On est donc dans la région critique $\rightarrow$ on **rejette** l'hypothèse nulle

Suggestion

- ☞ Bien qu'on n'ait pas besoin de comprendre les détails pour exécuter un test t et pour bien interpréter ses résultats, il est **très utile** de connaître la logique impliquée : c'est une logique qui joue toujours un rôle important dans la statistique traditionnelle.

Références

Garcia, G. D. (2024,). *Méthodes expérimentales et analyse de données*.