

Méthodes expérimentales et analyse de données

Ing-1100

Analyse de données : test $t \rightarrow$ ANOVA

Séance 5

Guilherme D. Garcia | fr.gdgarcia.ca/Ing1100



Révision du chapitre 4 • test t

1. Dans quelles conditions pouvons-nous utiliser le test t ?
2. Quelle est la fonction et la syntaxe pour exécuter le test?
3. Quelle est l'hypothèse nulle dans un test t ?
4. Quelle est l'interprétation de la valeur p ?
5. Qu'est-ce qu'on voit dans le résultat d'un test t ?
6. Quelles sont les limitations du test t ?

Révision • test t

1. Pour vérifier si deux groupes sont statistiquement différents par rapport à une variable **continue**, ou pour vérifier si un groupe est statistiquement différent d'une valeur spécifique (normalement, zéro)
2. `t.test(y ~ x, data = ...)`
3. Que les moyennes des groupes sont identiques : $\mu_A = \mu_B$ ou que la moyenne d'un groupe est identique à zéro (ou à la valeur définie par l'utilisateur)
4. C'est la probabilité de voir les données (et la différence) en question si l'hypothèse nulle est vraie
5. La valeur p , l'intervalle de confiance à 95 %, les moyennes pertinentes, les degrés de liberté (ddl), la valeur t
6. 1 ou 2 groupes; juste une variable analysable (groupe); très simpliste

Révision du chapitre 5 : test t

☞ Voyons le calcul de la variance et de la statistique t

- La variance (s^2) est la somme des écarts au carré divisée par $n - 1$:

Groupe A	$(x_i - \bar{x})^2$	Groupe B	$(x_i - \bar{x})^2$
87		76	
57		89	
48		95	
90		67	
91		58	
$\bar{x} = 74,6$		$\bar{x} = 77$	

Révision : test t

☞ Voyons le calcul de la variance et de la statistique t :

- La variance (s^2) est la somme des écarts au carré divisée par $n - 1$:

Groupe A	$(x_i - \bar{x})^2$	Groupe B	$(x_i - \bar{x})^2$
87	153,76	76	1
57	309,76	89	144
48	707,56	95	324
90	237,16	67	100
91	268,96	58	361
$\bar{x} = 74,6$	$s^2 = \frac{1677,2}{4} = 419,3$	$\bar{x} = 77$	$s^2 = \frac{930}{4} = 232,5$

Révision : test t


$$\Rightarrow \bar{x}_A = 74,6 \quad s_A^2 = 419,3 \quad \bar{x}_B = 77 \quad s_B^2 = 232,5 \quad n_A = n_B = 5$$

$$t = \frac{\bar{x}_A - \bar{x}_B}{\sqrt{\frac{s_A^2}{n_A} + \frac{s_B^2}{n_B}}}$$

$$t = \frac{74,6 - 77}{\sqrt{\frac{419,3}{5} + \frac{232,5}{5}}} = \frac{-2,4}{\sqrt{130,36}} = -0,21$$

Quand il y a plus de 2 groupes

☞ **Hypothèse nulle** : a, b et c ne sont pas différents; ils viennent de la **même population** ($p \geq 0,05$). Autrement dit, $\mu_a = \mu_b = \mu_c$.



Population

☞ **Hypothèse alternative** : il y a au moins **une** différence parmi les trois groupes.

Scénarios :

$$\mu_a = \mu_b \neq \mu_c$$

$$\mu_a \neq \mu_b = \mu_c$$

$$\mu_a \neq \mu_b \neq \mu_c$$

Les limitations du test t

- On a souvent plus de deux groupes dans notre analyse
- En plus, on veut analyser plusieurs variables en même temps

☞ Un test t est simplement **trop limité**

Aujourd'hui : **ANOVA** (*ANalysis Of VAriance*); un type spécial de **régression**

- Une méthode qui nous permet d'analyser plusieurs groupes/variables en même temps
- Ici, l'ANOVA sera examinée de façon temporaire : on cible les régressions complètes

☞ Mais il est important de connaître l'ANOVA : la littérature contient beaucoup d'articles qui l'utilisent

test t → ANOVA → **régressions**

Révision du chapitre 5 · questions de base

1. Si on examine 5 villes dans notre fichier, combien de tests t faudra-t-il exécuter pour comparer toutes les villes?
2. Quel est le problème de cette approche?
3. Quels sont les deux types d'erreurs pertinents à l'analyse de données?

Révision du chapitre 5 · correction

1. $_{10}$ (AB, AC, AD, AE, BC, BD, BE, CD, CE, DE)

2. Le taux d'erreur de **type 1** explose

3. Type 1 (faux positif) et type 2 (faux négatif)

$$\frac{k(k-1)}{2}$$

$$1 - (1 - \alpha)^{10}$$

Erreurs

Nos possibilités

	H_0 est vraie	H_0 est fausse
on rejette H_0	Type I	
on ne rejette pas H_0		Type II

Exemple classique : un test de **grossesse**

- **Positif** mais la personne n'est pas enceinte
- **Négatif** mais la personne est enceinte

erreur de type I
erreur de type II

☞ Ces concepts sont pertinents quelle que soit la méthode qu'on utilise dans le cours

ANOVA

Concepts de base

- L'idée générale : $F = \frac{\text{variabilité entre les groupes}}{\text{variabilité à l'intérieur des groupes}}$

☞ Si $F > 1$, peut-être que les groupes sont différents

Vrai ou faux?

1. Une ANOVA nous montre où sont les différences entre des groupes
2. La fonction utilisée pour exécuter une ANOVA est `anova()`
3. L'hypothèse alternative (H_1) d'une ANOVA est que tous les groupes sont différents

Vrai ou faux? · correction

1. Une ANOVA nous montre où sont les différences entre des groupes
2. La fonction utilisée pour exécuter une ANOVA est `anova()`
3. L' H_1 d'une ANOVA est que tous les groupes sont différents

FAUX

FAUX

FAUX

Qu'est-ce que la variance...?

La variabilité à l'intérieur des groupes

- Si l'ANOVA cible la variance, il faut bien comprendre la définition de **variance**
- Voici les premières lignes de `villes2.csv` (version simplifiée)

👉 Analysons notre tableau : pour Calgary, la note moyenne est 67.

	note	ville
1	52,47	Calgary
2	68,67	Calgary
3	48,29	Calgary
4	96,91	Calgary
5	71,59	Calgary
6	48,59	Calgary
...	...	...

Qu'est-ce que la variance...?

La variabilité à l'intérieur des groupes

- On calcule la **différence** (l'écart) entre chaque note et la moyenne du groupe
- Après, on calcule le **carré** de l'écart (ce qui nous donnera juste des valeurs positives)

	note	ville	moyenne	note-moyenne	(note-moyenne) ²
1	52,47	Calgary	67,00	-14,53	211,09
2	68,67	Calgary	67,00	1,67	2,80
3	48,29	Calgary	67,00	-18,71	350,16
4	96,91	Calgary	67,00	29,91	894,35
5	71,59	Calgary	67,00	4,59	21,07
6	48,59	Calgary	67,00	-18,41	338,90
...	...	...	...	...	...

$$\frac{\text{somme}}{N-k}$$

- La variance à l'intérieur des groupes sera la **somme totale divisée par $N - k$**
- N = nombre total d'observations; k = nombre de groupes (villes ici)

ANOVA

Concepts de base

- L'idée générale : $F = \frac{\text{variabilité entre les groupes}}{\text{variabilité à l'intérieur des groupes}}$

☞ Maintenant, calculons la variabilité **entre** les groupes

Qu'est-ce que la variance...?

La variabilité entre les groupes

- Calculez les **moyennes** par groupe ainsi que la **différence** entre leurs moyennes et la moyenne générale ($\bar{x} = 70,25$)
- Après, multipliez les carrés des écarts (CE) par le nombre d'observations (n) → **n_CE**

	ville	moyenne	n	diff	CE	n_CE
1	Calgary	67,01	50	-3,25	10,54	526,90
2	Montréal	69,58	50	-0,67	0,45	22,54
3	Québec	74,17	50	3,92	15,35	767,38

$$\frac{\text{somme}}{k-1}$$

- La somme totale est donc divisée par $k - 1$, et cela sera notre variabilité entre les groupes

Pratique

Chapitre 5

- Examinons le code et les exercices dans [le chapitre](#)

ANOVA + R

- Heureusement, il y a une fonction qui automatise le calcul pour nous : `aov()`

Pratique

Complétez le script `seance-5.R` :

1. Calculez les moyennes et les écarts-types des cinq groupes
2. Visualisez les données et exécutez une ANOVA
3. Pouvons-nous rejeter l'hypothèse nulle? Générez des comparaisons multiples
4. Avons-nous des erreurs dans les résultats?
5. Communiquez les résultats en utilisant le modèle présenté dans le chapitre
6. **Bonus** : analysez les scores de lecture (`read`) du PISA pour le Canada (`CAN`), la France (`FRA`) et l'Espagne (`ESP`). Créez une figure avant d'exécuter l'ANOVA + Tukey.

1 Annexe : la distribution F

La distribution F


Pour mieux comprendre la logique de l'ANOVA

1. On calcule les **variabilités** et la valeur F
 2. Ensuite, avec les **degrés de liberté** des données (2 et 147 pour `villes2.csv`)¹, on consulte un **tableau** de valeurs critiques. Pour $\alpha = 0,05$ et une hypothèse bilatérale, cette valeur sera de $\approx 3,06$.
Donc, si notre valeur F est supérieure à cette valeur, on sera dans la **région critique**, ce qui nous permettra de rejeter l'hypothèse nulle
- ☞ Examinez le tableau en question : quelle est la relation entre les degrés de liberté et les valeurs critiques de F ?

¹Nombre de groupes (3) – 1. Nombre d'observations (150) – nombre de groupes (3).

La distribution F


Visualisons nos données



- Après avoir calculé F (ou après avoir exécuté `aov( ... )`), on arrive à $F = 5,82$
- (Ici, la variance de Calgary est immense, ce qui serait un problème pour l'analyse!)

La distribution F

La région critique (rouge) = 5 % de la distribution



👉 5,82 (ligne pointillée) est **beaucoup** plus élevé que 3,06, la valeur critique pour $F(2, 147)$

- On est donc dans la région critique → on **rejette** l'hypothèse nulle

Commentaires finaux

Test t vs ANOVA

- L'ANOVA et le test t supposent que la variable de réponse est **normale**
- En plus, les deux méthodes supposent que la variance est la même à travers les groupes
- Le test t est limité à 1 ou 2 groupes; l'ANOVA est libre
- L'ANOVA peut avoir plusieurs variables : `aov(y ~ x + w + z)`
- Ces méthodes nous donnent une valeur p , ce qui nous permet de rejeter ou de ne pas rejeter l'hypothèse nulle. La statistique nous permet de conclure si un effet ou si une différence est **significative** ou **crédible**. Notre analyse ne doit pourtant pas se concentrer simplement sur les valeurs p !

👉 Les deux méthodes servent de point de départ pour le cours