

# Méthodes expérimentales et analyse de données

## Ing-1100

Analyse de données : test  $t \rightarrow$  ANOVA

Séance 5

Guilherme D. Garcia | [fr.gdgarcia.ca/Ing1100](http://fr.gdgarcia.ca/Ing1100)



## Révision du chapitre 4 • test $t$

1. Dans quelles conditions pouvons-nous utiliser le test  $t$ ?
2. Quelle est la fonction et la syntaxe pour exécuter le test?
3. Quelle est l'hypothèse nulle dans un test  $t$ ?
4. Quelle est l'interprétation de la valeur  $p$ ?
5. Qu'est-ce qu'on voit dans le résultat d'un test  $t$ ?
6. Quelles sont les limitations du test  $t$ ?

## Révision • test $t$

1. Pour vérifier si deux groupes sont statistiquement différents par rapport à une variable **continue**, ou pour vérifier si un groupe est statistiquement différent d'une valeur spécifique (normalement, zéro)
2. `t.test(y ~ x, data = ...)`
3. Que les moyennes des groupes sont identiques :  $\mu_A = \mu_B$  ou que la moyenne d'un groupe est identique à zéro (ou à la valeur définie par l'utilisateur)
4. C'est la probabilité de voir les données (et la différence) en question si l'hypothèse nulle est vraie
5. La valeur  $p$ , l'intervalle de confiance à 95 %, les moyennes pertinentes, les degrés de liberté (ddl), la valeur  $t$
6. 1 ou 2 groupes; juste une variable analysable (groupe); très simpliste

## Révision du chapitre 5 : test $t$

☞ Voyons le calcul de la variance et de la statistique  $t$

- La variance ( $s^2$ ) est la somme des écarts au carré divisée par  $n - 1$  :

| Groupe A         | $(x_i - \bar{x})^2$ | Groupe B       | $(x_i - \bar{x})^2$ |
|------------------|---------------------|----------------|---------------------|
| 87               |                     | 76             |                     |
| 57               |                     | 89             |                     |
| 48               |                     | 95             |                     |
| 90               |                     | 67             |                     |
| 91               |                     | 58             |                     |
| $\bar{x} = 74,6$ |                     | $\bar{x} = 77$ |                     |

## Révision : test $t$

☞ Voyons le calcul de la variance et de la statistique  $t$  :

- La variance ( $s^2$ ) est la somme des écarts au carré divisée par  $n - 1$  :

| Groupe A         | $(x_i - \bar{x})^2$              | Groupe B       | $(x_i - \bar{x})^2$           |
|------------------|----------------------------------|----------------|-------------------------------|
| 87               | 153,76                           | 76             | 1                             |
| 57               | 309,76                           | 89             | 144                           |
| 48               | 707,56                           | 95             | 324                           |
| 90               | 237,16                           | 67             | 100                           |
| 91               | 268,96                           | 58             | 361                           |
| $\bar{x} = 74,6$ | $s^2 = \frac{1677,2}{4} = 419,3$ | $\bar{x} = 77$ | $s^2 = \frac{930}{4} = 232,5$ |

## Révision : test $t$


$$\Rightarrow \bar{x}_A = 74,6 \quad s_A^2 = 419,3 \quad \bar{x}_B = 77 \quad s_B^2 = 232,5 \quad n_A = n_B = 5$$

$$t = \frac{\bar{x}_A - \bar{x}_B}{\sqrt{\frac{s_A^2}{n_A} + \frac{s_B^2}{n_B}}}$$

$$t = \frac{74,6 - 77}{\sqrt{\frac{419,3}{5} + \frac{232,5}{5}}} = \frac{-2,4}{\sqrt{130,36}} = -0,21$$

# Quand il y a plus de 2 groupes

☞ **Hypothèse nulle** : **a**, **b** et **c** ne sont pas différents; ils viennent de la **même population** ( $p \geq 0,05$ ). Autrement dit,  $\mu_a = \mu_b = \mu_c$ .



**Population**

☞ **Hypothèse alternative** : il y a au moins **une** différence parmi les trois groupes.

Scénarios :

$$\mu_a = \mu_b \neq \mu_c$$

$$\mu_a \neq \mu_b = \mu_c$$

$$\mu_a \neq \mu_b \neq \mu_c$$

# Les limitations du test $t$

- On a souvent plus de deux groupes dans notre analyse
- En plus, on veut analyser plusieurs variables en même temps

☞ Un test  $t$  est simplement **trop limité**

Aujourd'hui : **ANOVA** (*ANalysis Of VAriance*); un type spécial de **régression**

- Une méthode qui nous permet d'analyser plusieurs groupes/variables en même temps
- Ici, l'ANOVA sera examinée de façon temporaire : on cible les régressions complètes

☞ Mais il est important de connaître l'ANOVA : la littérature contient beaucoup d'articles qui l'utilisent

test  $t$   $\rightarrow$  ANOVA  $\rightarrow$  **régressions**

## Révision du chapitre 5 · questions de base

1. Si on examine 5 villes dans notre fichier, combien de tests  $t$  faudra-t-il exécuter pour comparer toutes les villes?
2. Quel est le problème de cette approche?
3. Quels sont les deux types d'erreurs pertinents à l'analyse de données?

## Révision du chapitre 5 · correction

1.  $_{10}$  (AB, AC, AD, AE, BC, BD, BE, CD, CE, DE)

2. Le taux d'erreur de **type 1** explose

3. Type 1 (faux positif) et type 2 (faux négatif)

$$\frac{k(k-1)}{2}$$

$$1 - (1 - \alpha)^{10}$$

# Erreurs

## Nos possibilités

|                         | $H_0$ est vraie | $H_0$ est fausse |
|-------------------------|-----------------|------------------|
| on rejette $H_0$        | Type I          |                  |
| on ne rejette pas $H_0$ |                 | Type II          |

Exemple classique : un test de **grossesse**

- **Positif** mais la personne n'est pas enceinte
- **Négatif** mais la personne est enceinte

erreur de type I  
erreur de type II

☞ Ces concepts sont pertinents quelle que soit la méthode qu'on utilise dans le cours

# ANOVA

## Concepts de base

- L'idée générale :  $F = \frac{\text{variabilité entre les groupes}}{\text{variabilité à l'intérieur des groupes}}$

☞ Si  $F > 1$ , peut-être que les groupes sont différents

### Vrai ou faux?

1. Une ANOVA nous montre où sont les différences entre des groupes
2. La fonction utilisée pour exécuter une ANOVA est `anova()`
3. L'hypothèse alternative ( $H_1$ ) d'une ANOVA est que tous les groupes sont différents

## Vrai ou faux? · correction

1. Une ANOVA nous montre où sont les différences entre des groupes
2. La fonction utilisée pour exécuter une ANOVA est `anova()`
3. L' $H_1$  d'une ANOVA est que tous les groupes sont différents

**FAUX**

**FAUX**

**FAUX**

# Qu'est-ce que la variance...?

## La variabilité à l'intérieur des groupes

- Si l'ANOVA cible la variance, il faut bien comprendre la définition de **variance**
- Voici les premières lignes de `villes2.csv` (version simplifiée)

👉 Analysons notre tableau : pour Calgary, la note moyenne est 67.

|     | note  | ville   |
|-----|-------|---------|
| 1   | 52,47 | Calgary |
| 2   | 68,67 | Calgary |
| 3   | 48,29 | Calgary |
| 4   | 96,91 | Calgary |
| 5   | 71,59 | Calgary |
| 6   | 48,59 | Calgary |
| ... | ...   | ...     |

# Qu'est-ce que la variance...?

## La variabilité à l'intérieur des groupes

- On calcule la **différence** (l'écart) entre chaque note et la moyenne du groupe
- Après, on calcule le **carré** de l'écart (ce qui nous donnera juste des valeurs positives)

|     | note  | ville   | moyenne | note-moyenne | (note-moyenne) <sup>2</sup> |
|-----|-------|---------|---------|--------------|-----------------------------|
| 1   | 52,47 | Calgary | 67,00   | -14,53       | 211,09                      |
| 2   | 68,67 | Calgary | 67,00   | 1,67         | 2,80                        |
| 3   | 48,29 | Calgary | 67,00   | -18,71       | 350,16                      |
| 4   | 96,91 | Calgary | 67,00   | 29,91        | 894,35                      |
| 5   | 71,59 | Calgary | 67,00   | 4,59         | 21,07                       |
| 6   | 48,59 | Calgary | 67,00   | -18,41       | 338,90                      |
| ... | ...   | ...     | ...     | ...          | ...                         |

$$\frac{\text{somme}}{N-k}$$

- La variance à l'intérieur des groupes sera la **somme totale divisée par  $N - k$**
- $N$  = nombre total d'observations;  $k$  = nombre de groupes (villes ici)

# ANOVA

## Concepts de base

- L'idée générale :  $F = \frac{\text{variabilité entre les groupes}}{\text{variabilité à l'intérieur des groupes}}$

☞ Maintenant, calculons la variabilité **entre** les groupes

# Qu'est-ce que la variance...?

## La variabilité entre les groupes

- Calculez les **moyennes** par groupe ainsi que la **différence** entre leurs moyennes et la moyenne générale ( $\bar{x} = 70,25$ )
- Après, multipliez les carrés des écarts (CE) par le nombre d'observations ( $n$ ) → **n\_CE**

|   | ville    | moyenne | $n$ | diff  | CE    | n_CE   |
|---|----------|---------|-----|-------|-------|--------|
| 1 | Calgary  | 67,01   | 50  | -3,25 | 10,54 | 526,90 |
| 2 | Montréal | 69,58   | 50  | -0,67 | 0,45  | 22,54  |
| 3 | Québec   | 74,17   | 50  | 3,92  | 15,35 | 767,38 |

$$\frac{\text{somme}}{k-1}$$

- La somme totale est donc divisée par  $k - 1$ , et cela sera notre variabilité entre les groupes

# Pratique

## Chapitre 5

- Examinons le code et les exercices dans [le chapitre](#)

# ANOVA + R

- Heureusement, il y a une fonction qui automatise le calcul pour nous : `aov()`

## Pratique

Complétez le script `seance-5.R` :

1. Calculez les moyennes et les écarts-types des cinq groupes
2. Visualisez les données et exécutez une ANOVA
3. Pouvons-nous rejeter l'hypothèse nulle? Générez des comparaisons multiples
4. Avons-nous des erreurs dans les résultats?
5. Communiquez les résultats en utilisant le modèle présenté dans le chapitre
6. **Bonus** : analysez les scores de lecture (`read`) du PISA pour le Canada (`CAN`), la France (`FRA`) et l'Espagne (`ESP`). Créez une figure avant d'exécuter l'ANOVA + Tukey.

# 1 Annexe : la distribution $F$

# La distribution $F$

## Pour mieux comprendre la logique de l'ANOVA


1. On calcule les **variabilités** et la valeur  $F$
  2. Ensuite, avec les **degrés de liberté** des données (2 et 147 pour `villes2.csv`)<sup>1</sup>, on consulte un **tableau** de valeurs critiques. Pour  $\alpha = 0,05$  et une hypothèse bilatérale, cette valeur sera de  $\approx 3,06$ .  
Donc, si notre valeur  $F$  est supérieure à cette valeur, on sera dans la **région critique**, ce qui nous permettra de rejeter l'hypothèse nulle
- ☞ Examinez le tableau en question : quelle est la relation entre les degrés de liberté et les valeurs critiques de  $F$ ?

---

<sup>1</sup>Nombre de groupes (3) – 1. Nombre d'observations (150) – nombre de groupes (3).

# La distribution $F$


## Visualisons nos données



- Après avoir calculé  $F$  (ou après avoir exécuté `aov( ... )`), on arrive à  $F = 5,82$
- (Ici, la variance de Calgary est immense, ce qui serait un problème pour l'analyse!)

# La distribution $F$

La région critique (rouge) = 5 % de la distribution



👉 5,82 (ligne pointillée) est **beaucoup** plus élevé que 3,06, la valeur critique pour  $F(2, 147)$

- On est donc dans la région critique → on **rejette** l'hypothèse nulle

# Commentaires finaux

## Test $t$ vs ANOVA

- L'ANOVA et le test  $t$  supposent que la variable de réponse est **normale**
- En plus, les deux méthodes supposent que la variance est la même à travers les groupes
- Le test  $t$  est limité à 1 ou 2 groupes; l'ANOVA est libre
- L'ANOVA peut avoir plusieurs variables : `aov(y ~ x + w + z)`
- Ces méthodes nous donnent une valeur  $p$ , ce qui nous permet de rejeter ou de ne pas rejeter l'hypothèse nulle. La statistique nous permet de conclure si un effet ou si une différence est **significative** ou **crédible**. Notre analyse ne doit pourtant pas se concentrer simplement sur les valeurs  $p$ !

👉 Les deux méthodes servent de point de départ pour le cours