

Méthodes expérimentales et analyse de données

Ing-1100

ANOVA → régression linéaire

Séances 6–7

Guilherme D. Garcia | fr.gdgarcia.ca/Ing1100



Plan de la séance

Dans RStudio aujourd'hui

1. ANOVA
2. Régression linéaire
3. Extra : l'erreur standard et le coefficient de détermination

☞ Commencez votre travail en équipe pour le problème 1 (consultez le chapitre + le tutoriel sur Quarto)

1 ANOVA : un type de régression

ANOVA · révision

- Vous voyez $F(4, 203)$ dans un article scientifique.
Combien de groupes et d'observations y a-t-il dans l'étude?
- Pourquoi ajustons-nous les valeurs p dans un test *post hoc*?
- L'effet d'une variable est-il présent dans le résultat d'une ANOVA? Pouvons-nous le déduire?

ANOVA · révision : correction

- 5 groupes et 208 observations dans une ANOVA à un facteur (le nombre d'observations est donc inégal entre les groupes)
- Pour réduire la probabilité des erreurs de type I (c.-à-d. conclure qu'il y a un effet alors que l'hypothèse nulle est vraie) : $1 - (1 - \alpha)^n$, où n représente le nombre de comparaisons multiples; $\alpha = 0,05$ dans notre cas
- Non : l'ANOVA nous donne uniquement les valeurs p , pas les effets d'intérêt

ANOVA

Révision

- **One-way** ANOVA → $y \sim x$ p. ex., note en fonction de ville
- **Two-way** ANOVA → $y \sim x + w$ p. ex., note en fonction de ville **et** langue maternelle
- ANCOVA → $y \sim x + z$ p. ex., note en fonction de ville et nombre d'heures d'étude¹

☞ On a vu un exemple d'ANOVA à un facteur seulement, mais la logique est la même

- Et vous pouvez toujours utiliser la même fonction : `aov( ... )`
- L'ANCOVA = plus générale : on a souvent des variables catégoriques et continues

¹Donc, une variable continue (z).

ANOVA → régression

- ANOVA : type spécial de **régression** — méthode très générale d'analyse de données

☞ Dans le cours, on utilisera la régression traditionnelle parce que :

1. elle est plus **puissante** et plus **complète**
2. ses résultats mettent l'accent sur l'**effet**, et non pas sur les valeurs p
3. la méthode est facilement généralisable
4. on veut **prédire** des données

Mais c'est quoi une « régression »?

Régression

Un processus naturel

- Un sprinter de haut niveau qui réalise un temps **exceptionnel** lors d'une course
- Lors des courses suivantes, son temps revient souvent à sa moyenne habituelle


☞ **Pourquoi?** La performance exceptionnelle est due en partie à des facteurs aléatoires :

- Conditions météorologiques favorables
 - Forme physique particulièrement bonne ce jour-là
 - Un simple coup de chance
 - ...
- Lors des prochaines courses, ces éléments fluctuants ne joueront pas forcément en sa faveur, et il reviendra à un niveau **plus représentatif** de ses capacités

☞ **Bref :** les performances extrêmes ont tendance à être suivies d'un retour à la normale

Régression vers la moyenne


Un processus naturel (figure à titre d'illustration)



- ➡ Plus une performance est exceptionnelle, plus il est probable que les prochaines performances seront moins exceptionnelles (on a un maximum, après tout!)

Régression linéaire

- Voici une figure qui contient une régression linéaire (`feedbackData.csv`) :



- Ici, on examine l'effet des **heures** (**variable continue**) d'étude sur la note
👉 « Quelle sera la différence dans la note pour chaque heure d'étude additionnelle? »

Régression linéaire

- Quelle est la meilleure droite pour les données?
- « Meilleure » → celle qui minimise les distances entre les points et elle-même
- Autrement dit, la droite qui génère la variance la plus basse possible pour les données en question

☞ On utilise deux paramètres pour définir la droite :

- l'**intercept** = β_0 (l'ordonnée à l'origine)
- le **slope** = β_1 (la pente)

Visualisons le concept : Jouer avec les paramètres [ici](#) (*Trend line*)


Régression linéaire

- Nos données (dernière séance) : **variable discrète ou catégorielle**
- Essentiellement la même chose → imaginez une droite entre les deux moyennes

Moyennes

Montréal : $\bar{x} = 69,6$

Québec : $\bar{x} = 74,2$



Régression linéaire

Synthèse de la première partie

- **Objectif** : trouver la meilleure droite pour nos données
- **L'idée principale** : la variable x a-t-elle un effet sur la variable y ?

L'hypothèse nulle (H_0) : **non**, c'est-à-dire que la droite entre les villes est **horizontale**

L'hypothèse alternative (H_1) : la droite n'est pas horizontale (positive ou négative)

- Comme le test t et l'ANOVA, la régression permet de **rejeter** ou de ne pas rejeter l' H_0

Régression linéaire

$$y_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i_1} + \hat{e}$$

- y_i = la réponse i (la note dans notre exemple); ce qu'on veut prédire/analyser
- $\hat{\beta}_0$ = notre constante, l'*intercept*. Donc, la valeur prévue ($\hat{y}_i$) quand $x_{i_1} = 0$
- $\hat{\beta}_1$ = notre effet pour la variable `ville`, le *slope*
- x_{i_1} = l'observation i pour la variable `ville`
- $\hat{e}$ = l'erreur (tout ce que le modèle ne peut pas prédire)
- i = une observation (une ligne dans le tableau)

☞ On utilise R pour trouver β_0 et β_1 ; l'idée sera plus claire dans quelques instants

y ou $\hat{y}$? L'accent circonflexe indique une valeur *prévue* par le modèle. Son absence indique la « réalité » : y = observation dans le tableau; $\hat{y}$ = prévision du modèle. β = valeur « réelle » pour la population (inconnue); $\hat{\beta}$ = valeur estimée par le modèle.

Régression linéaire en R

Exécuter la régression

- Pour exécuter une régression linéaire, on utilise la fonction `lm(y ~ x)` :

```
# Chargez les extensions :  
library(tidyverse)  
  
# Importer les données :  
villes ← read_csv("donnees/villes.csv")  
  
# Visualiser les données :  
# ...  
  
# Régression :  
mod1 ← lm(note ~ ville, data = villes)  
  
summary(mod1)
```

Régression linéaire en R

Interpréter le résultat

- Pour interpréter les résultats, on se concentre sur trois éléments :

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	69.5838	0.7905	88.025	< 2e-16 ***
villeQuébec	4.5890	1.1179	4.105	8.38e-05 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.59 on 98 degrees of freedom

Multiple R-squared: 0.1467, Adjusted R-squared: 0.138

F-statistic: 16.85 on 1 and 98 DF, p-value: 8.38e-05

Régression linéaire en R

Interpréter le résultat

```
Coefficients:
      Estimate Std. Error t value Pr(>|t|)  2
(Intercept)  69.5838    0.7905  88.025  < 2e-16  **
villeQuébec   4.5890    1.1179   4.105  8.38e-05  **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.59 on 98 degrees of freedom
Multiple R-squared:  0.1467,    Adjusted R-squared:  0.138  3
F-statistic: 16.85 on 1 and 98 DF,  p-value: 8.38e-05
```

1. Les coefficients ($\hat{\beta}$) : l'intercept (Montréal) et le slope (Québec)
2. Les valeurs p (ici, les deux sont minuscules)
3. Le R^2 : le coefficient de détermination indique la proportion des notes expliquée par `ville`

Régression linéaire en R

Interpréter le résultat

```
Coefficients:
      Estimate Std. Error t value Pr(>|t|)  2
(Intercept)  69.5838      0.7905  88.025  < 2e-16  **
villeQuébec   4.5890      1.1179   4.105  8.38e-05  **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.59 on 98 degrees of freedom
Multiple R-squared:  0.1467,    Adjusted R-squared:  0.138  3
F-statistic: 16.85 on 1 and 98 DF,  p-value: 8.38e-05
```

1. L'intercept = la note moyenne de Montréal; le slope = la différence entre Montréal et Québec
2. Les valeurs p nous disent que les deux effets sont statistiquement significatifs
3. 13,8 % de la variation des notes est expliquée par la ville des apprenants

Régression linéaire en R

Générer les intervalles de confiance

```
confint(mod1)
```

	2.5 %	97.5 %
(Intercept)	68.01507	71.15253
villeQuébec	2.37048	6.80752

Intervalle de confiance (IC) au niveau de 95 % :

☞ la probabilité que la moyenne de la population (μ) se trouve dans l'intervalle

- Il est important de communiquer nos intervalles ainsi que nos effets : les IC rendent nos résultats plus précis et plus transparents
- **Règle** : si l'intervalle inclut zéro, la valeur p sera supérieure à 0,05

Régression linéaire

Imprimer un tableau facilement dans RStudio

```
# install.packages("sjPlot")
library(sjPlot)

mod1 ►
  tab_model(
    title = "Tableau statistique
             de la régression",
    dv.labels = "",
    string.pred = "Variables",
    string.ci = "IC 95%",
    string.est = "Coefficients",
    string.p = "Valeur p")
```

Tableau statistique de la régression		
Variables	Coefficients	IC 95%
Intercept	69.58	68.02 – 71.15
Age	4.59	2.37 – 6.81
N	100	
Adjusted R-squared	0.147 / 0.138	

2 Prédiction, visualisation, pratique

Régression linéaire en R

Notre modèle

$$y_i = \overbrace{\hat{\beta}_0}^{\text{Montréal}} + \overbrace{\hat{\beta}_1 x_{i_1}}^{\text{Québec}} + \hat{e}$$

$$y_i = 69,58 + 4,59 \cdot 1 + \hat{e}$$

$$y_i = 69,58 + 4,59 \cdot 0 + \hat{e}$$

1. Pour prédire la note moyenne des apprenants à Québec
2. Pour prédire la note moyenne des apprenants à Montréal

Obs. L'accent circonflexe veut dire « estimé-e »

Régression linéaire

Conclusion

- **ville** a un effet statistiquement significatif sur la variable **note** ($\hat{\beta} = 4,59$, IC 95 % = [2,4, 6,8], $p < 0,0001$). En plus, la ville d'un apprenant explique environ 14 % de la variation observée pour les notes des groupes. Autrement dit, la différence entre les deux groupes est réelle : on rejette l' H_0
- L'intercept (β_0) est notre niveau de référence (Montréal)²
- Donc, c'est le slope qui montre la **différence** entre les groupes

²R sélectionne automatiquement le premier niveau de la variable (alphabétiquement).

Pratique · une ville de plus

1. Importez le fichier `villes2.csv`
2. Explorez les différences entre les groupes par rapport à la variable `ville`
3. Créez une figure pour les variables `ville` et `note`
4. Exécutez un modèle linéaire avec ces variables
5. Interprétez les résultats
6. Répétez les étapes 3–5 avec les variables `duree` (temps d'étude du français) et `note`

Pratique • correction

```
library(tidyverse)

# 1-2. Importer et explorer
villes2 <- read_csv("donnees/villes2.csv")

villes2 >
  summarize(moyenne = mean(note), ec_type = sd(note), .by = ville)

# 3. Figure
villes2 >
  ggplot(aes(x = ville, y = note)) +
  geom_boxplot()
```

Pratique • correction

```
# 4-5. Modèle linéaire et interprétation
mod2 ← lm(note ~ ville, data = villes2)

summary(mod2)
confint(mod2)
```

- ☞ Avec trois villes, on a maintenant **deux slopes** : chacun compare une ville au niveau de référence (Calgary), et non les villes entre elles

Pratique • correction

```
# 6. La même chose avec une variable continue (duree)
villes2 ▷
  ggplot(aes(x = duree, y = note)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm")

mod3 ← lm(note ~ duree, data = villes2)
summary(mod3)
```

👉 La **syntaxe** est identique : seule l'interprétation du slope change. Pour **duree**, $\hat{\beta}_1$ est la différence de note pour **chaque unité** de temps d'étude

Vrai ou faux? Justifiez votre réponse

Révision des concepts

1. L'intercept représente la moyenne globale pour la variable y
2. Si une variable x est un facteur de 6 niveaux, on aura 5 *slopes* dans notre modèle
3. Si l'intercept est 0, on accepte l'hypothèse nulle
4. L'effet d'une variable est représenté par $\hat{\beta}$
5. La fonction pour calculer les intervalles de confiance est `conf.int()`
6. Dans une régression linéaire, les effets sont interprétés par rapport à un niveau de référence : $\hat{\beta}_1$

Vrai ou faux? · correction

1. **FAUX** — c'est la moyenne du *niveau de référence* (ou la valeur de y quand les prédicteurs valent 0)
2. **VRAI** — un facteur de k niveaux donne $k - 1$ slopes; le niveau restant est l'intercept
3. **FAUX** — on ne rejette jamais l' H_0 à partir de l'intercept, et on ne l'*accepte* jamais : on ne la rejette pas
4. **VRAI** — $\hat{\beta}$ est l'effet estimé de la variable
5. **FAUX** — la fonction est `confint()`
6. **FAUX** — le niveau de référence est l'intercept, $\hat{\beta}_0$, et non $\hat{\beta}_1$


Synthèse

- On utilise une régression linéaire s'il y a une **relation linéaire** entre nos variables
- L'idée est de trouver la meilleure droite pour les données (outil interactif [ici](#))
- L'intercept est notre coefficient de référence ($\hat{\beta}_0$) : la réponse quand les autres variables prédictives = 0
- Le slope est normalement le coefficient d'intérêt ($\hat{\beta}_x$)

👉 **Plus d'information** : Garcia (2021, chap. 6) (anglais) et Barnier (2024, chap. 21) (français)

Synthèse

👉 Notez que la logique sous-jacente est la même pour les variables x catégoriques ou continues



Synthèse


Les coefficients et l'hypothèse nulle (la variable x pourrait être continue ici)

☞ $H_0 = 0$ (on l'a déjà rejetée)

Considérons les scénarios suivants :

Scénario	Rejetons l' H_0 de...	
	$\hat{\beta}_0$	$\hat{\beta}_1$
a	non	non
b	non	oui
c	oui	oui
d	oui	non

- `villes.csv` → scénario **c** (retournez à la [diapo 10](#))



Pratique · une variable de plus

On peut avoir plusieurs variables prédictives : $y \sim x + w + z \dots$

1. Créez une figure pour `note`, `ville` et `duree`
2. Exécutez un modèle linéaire avec ces variables
3. Interprétez les résultats : nos conclusions changent-elles?
4. Maintenant, exécutez une régression juste avec `duree`. Qu'est-ce que vous remarquez dans les résultats?
5. **Extra** : reproduisez la figure dans la prochaine diapo (à la maison)

Pratique • correction


```
# 1. Une figure avec les trois variables
villes2 ▶
  ggplot(aes(x = duree, y = note, colour = ville)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm", se = FALSE)

# 2-3. Modèle additif
mod4 ← lm(note ~ ville + duree, data = villes2)
summary(mod4)

# 4. Modèle avec duree seulement
mod5 ← lm(note ~ duree, data = villes2)
summary(mod5)
```

Pratique

Figure à reproduire



Notre modèle avec trois villes

Pour comprendre sa structure

$$y_i = \overbrace{\hat{\beta}_0}^{\text{Calgary}} + \overbrace{\hat{\beta}_1 x_{i_1}}^{\text{Montréal}} + \overbrace{\hat{\beta}_2 x_{i_2}}^{\text{Québec}} + \hat{e}$$

1. Pour prédire la note moyenne des apprenants à **Calgary**
2. Pour prédire la note moyenne des apprenants à **Montréal**
3. Pour prédire la note moyenne des apprenants à **Québec**

$$\begin{aligned} \rightarrow \hat{\beta}_0 + \cancel{\hat{\beta}_1 \cdot 0} + \cancel{\hat{\beta}_2 \cdot 0} &= \hat{\beta}_0 \\ \rightarrow \hat{\beta}_0 + \hat{\beta}_1 + \cancel{\hat{\beta}_2 \cdot 0} & \\ \rightarrow \hat{\beta}_0 + \cancel{\hat{\beta}_1 \cdot 0} + \hat{\beta}_2 & \end{aligned}$$

- Considérez le modèle `note ~ duree` et le modèle `note ~ ville`

👉 Réfléchissez à la différence entre une variable catégorielle et une variable continue

Pratique à la maison

Notre modèle avec trois villes + temps d'étude

$$y_i = \overbrace{\hat{\beta}_0}^{\text{Calgary}} + \overbrace{\hat{\beta}_1 x_{i_1}}^{\text{Montréal}} + \overbrace{\hat{\beta}_2 x_{i_2}}^{\text{Québec}} + \overbrace{\hat{\beta}_3 x_{i_3}}^{\text{temps d'étude}} + \hat{e}$$

Un modèle avec les deux variables prédictives : `note ~ ville + duree`

L'intercept?

Dans le modèle ci-dessus, quelle est l'interprétation de l'intercept?

L'intercept? · correction

☞ $\hat{\beta}_0$ = la note prédite pour un apprenant de **Calgary** (le niveau de référence) dont la **durée d'étude est de zéro**

- Avec une variable continue dans le modèle, l'intercept n'est plus la moyenne d'un groupe : c'est la valeur prédite quand **toutes** les variables prédictives valent 0
- Ici, `durée = 0` n'existe peut-être pas dans les données → l'intercept devient difficile à interpréter
- **Solution courante** : centrer la variable continue (`durée - mean(durée)`), ce qui rend l'intercept interprétable comme la note d'un apprenant de Calgary ayant une durée d'étude **moyenne**

Comparaisons multiples?

- On a vu que tous les effets doivent être comparés à l'intercept
- Mais parfois il est utile/nécessaire de comparer *tous* les niveaux d'un facteur
- Par exemple, y a-t-il une différence entre **Montréal** et **Québec**...?

Pratique

- Comment effectuer des comparaisons multiples à partir d'une régression linéaire?
- ☞ Discutez du chapitre 7 avec vos collègues et répondez aux questions du chapitre

Comparaisons multiples · correction

```
library(emmeans)

mod2 ← lm(note ~ ville, data = villes2)


# Toutes les paires de niveaux, avec ajustement des valeurs p
mod2 ▷
  emmeans(pairwise ~ ville, adjust = "tukey")
```

☞ L'ajustement est essentiel : le taux d'erreur de type I exploserait, $1 - (1 - \alpha)^n$ (voir la séance 5)

Extra

L'erreur standard

- On utilise souvent l'erreur standard des moyennes dans les figures :



- Cet élément nous donne une idée de la variabilité dans les données

L'erreur standard

L'erreur standard est **l'écart type de la distribution d'échantillonnage**

1. Considérez une population de 20 000 personnes
2. Prenez un échantillon de 50 personnes et calculez la moyenne
3. Répétez l'étape 2 plusieurs fois (p. ex., 100), ce qui vous donne 100 moyennes

☞ L'écart type de ces moyennes est l'erreur standard de la moyenne

- On peut estimer l'erreur standard manuellement : $ES = \frac{s}{\sqrt{n}}$
- Finalement, on peut calculer les intervalles de confiance au niveau de 95 % : $\bar{x} \pm 1,96 \cdot ES$

code [ici](#)

R^2 vs r

- On a parlé du **coefficient de détermination**, le R^2 . Ce coefficient $[0, +1]$ nous donne la proportion de la variabilité expliquée dans la variable y par le modèle.
 - La **corrélation** de deux variables, le r , nous donne l'intensité de la relation entre deux variables $[-1, +1]$.
On ne va pas explorer ce coefficient dans notre cours.
 - On peut arriver au R^2 à partir du r (r^2) et vice versa, mais quand on calcule la corrélation à partir du R^2 on n'a pas la direction de la corrélation ($r = \sqrt{R^2}$).
- ☞ Donc, une corrélation de -0,5 ou de 0,5 nous donne un R^2 de 0,25 (la direction de la corrélation est perdue dans le R^2)

Références

Barnier, J. (2024). *Introduction à R et au tidyverse*.

Garcia, G. D. (2021). *Data visualization and analysis in second language research*. Routledge.