Méthodes expérimentales et analyse de données

LNG−1100

Les variables binaires et le nettoyage des données

Séance 9

Guilherme D. Garcia | fr.gdgarcia.ca/lng1100



Plan de la séance

1. Des variables catégorielles (binaires)
2. Pratique en R

Questionnaire 1

Collecte de données : forms.office.com/r/fcKjiCAx9p



Questionnaire 2

Collecte de données : forms.office.com/r/9yfdeMsw2W



Pratique · des données réalistes

1. Importez les données `questionnaire.csv` : résultats à partir de MS Forms
2. Le tableau est-il *tidy*?
3. Quels problèmes constatez-vous dans le tableau?

Des données réalistes · correction

Nos données sont fréquemment chaotiques :

- format *wide* (pas *tidy*);
- plusieurs colonnes inutiles;
- noms longs pour les variables/colonnes;
- des NAs.

☞ Heureusement, on peut régler tous ces problèmes dans notre script

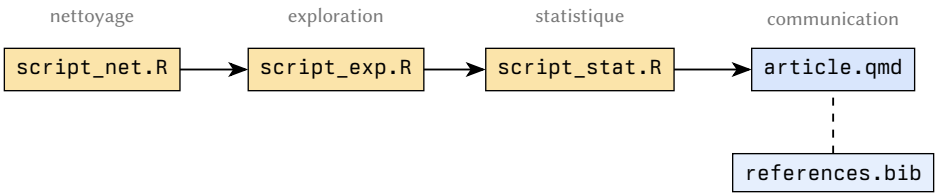
Une structure de travail organisée

L'analyse de données contient plusieurs étapes :

- importation et **nettoyage** des données avec `tidyverse` et `janitor` ;
- visualisation des patrons;
- analyse statistique;
- communication des résultats (Quarto, etc.).

☞ Jusqu'ici, on a utilisé un seul script pour toutes les étapes (pas idéal!)

Une structure de travail organisée



- Chaque **script** est responsable d'une étape : **nettoyage, exploration, analyse statistique**

☞ On utilise la fonction `source("script_net.R")` pour charger un script

Une structure de travail organisée

Aujourd'hui

- On travaille dans la **première étape** : `seance-9-net-q1.R`
- C'est un script normal : on charge les extensions et on importe les données

Pratique · nettoyage

- Importez et nettoyez le fichier `questionnaire.csv`
- N'oubliez pas d'enlever la colonne qui indique le nom des participants

Facteurs et niveau de référence

- Dans une régression, la référence (l'*intercept*) est le **premier niveau** du facteur
- `as_factor()` : ordre d'apparition · `factor()` : ordre alphabétique

```
villes ← read_csv("donnees/villes2.csv") ▷ mutate(ville = as_factor(ville))
levels(villes$ville)  # "Calgary"  "Montréal"  "Québec"

villes ← villes ▷ mutate(ville = fct_relevel(ville, "Québec"))
levels(villes$ville)  # "Québec"  "Calgary"  "Montréal"

lm(note ~ ville, data = villes)  # intercept = 74,17 (moyenne de Québec)
```

☞ Après `as_factor()`, vérifiez toujours `levels()` et fixez la référence avec `fct_relevel()`

Pratique · bonus

- Quel est le score de chaque participant?
- Le goût pour la géographie affecte-t-il la précision des réponses?
- Créez une figure que vous considérez appropriée.